

INFORME SISTEMA DE RECOMENDACIÓN HÍBRIDO

Sistema de recomendación híbrido para negocios basado en filtrado colaborativo y contenido

Integrantes:

Alvaro Castiblanco, Bryan Guzman, Juan Tovar, Lorraine Rojas

Enlace aplicación: [Yelp Smart Recommender · Streamlit](#)

Enlace repositorio: [Repositorio Github](#)

1. Introducción

En los últimos años los sistemas de recomendación se han convertido en herramientas fundamentales para personalizar experiencia de usuarios ya que, se encuentran en plataformas que permiten filtrar grandes cantidades de información y presentar contenido relevante de acuerdo con los gustos, preferencias y comportamientos de cada usuario.

En este taller se presenta el diseño e implementación de un sistema de recomendación híbrido para la plataforma Yelp, cuyo objetivo principal es maximizar la relevancia de las sugerencias mediante la integración de dos enfoques complementarios. Por un lado, se utiliza el filtrado colaborativo a través de TruncatedSVD para capturar patrones históricos de consumo y, por otro, un modelo sensible al contexto que adapta las recomendaciones a factores situacionales como la ubicación y el tiempo.

En sistema diseñado además de generar recomendaciones, también implementa mecanismos de explicabilidad para mostrar al usuario las razones por las cuales un negocio fue sugerido, incrementando la interpretabilidad y confianza en el sistema.

2. Glosario

1. Filtrado Colaborativo: Factorización Matricial (TruncatedSVD) El núcleo del sistema emplea una técnica de filtrado colaborativo fundamentada en la Factorización Matricial mediante el algoritmo TruncatedSVD. Esta metodología permite descomponer la matriz de interacciones (usuario-película) en componentes de menor dimensión, identificando factores latentes que representan patrones, el objetivo es reducir el universo en el cual se hace la búsqueda, por ejemplo, si una persona ha visto una película y la ha calificado, el algoritmo identifica a las personas que ya han calificado la misma película, y de esta forma reduce el universo, identificando los grupos con gustos similares (vectores de preferencia similares), una vez reducido el grupo empieza a evaluar cuales son las películas que los otros usuarios han visto, para de esta forma recomendar con mayor probabilidad la siguiente película.

2. Modelo de Recomendación Sensible al Contexto: Se consideran variables externas como el momento de la visualización (is_weekend), la ubicación geográfica (city) y la categoría del contenido. Este enfoque permite al algoritmo discernir, por ejemplo, que las preferencias de un usuario pueden estar entre un documental educativo durante la semana laboral y un película de acción en el fin de semana, optimizando la relevancia de la sugerencia según la situación actual del espectador.

3. Arquitectura del Recomendador Híbrido: La solución propuesta implementa una arquitectura híbrida que busca mitigar las limitaciones individuales de cada técnica. Mediante un parámetro de ponderación denominado Alpha (α), el sistema equilibra las predicciones del filtrado colaborativo con las del modelo contextual. Esta combinación es crucial para resolver problemas de densidad de datos; si el modelo colaborativo carece de historial suficiente para un usuario, el componente contextual actúa como un respaldo lógico, asegurando que la recomendación sea siempre coherente y personalizada.

4. Evaluación Offline y Sintonización de Hiperparámetros: Para garantizar la validez científica del modelo, se realizó una evaluación offline utilizando métricas de error como el RMSE (Root Mean Square Error). El proceso de sintonización consiste en ajustar sistemáticamente los pesos del modelo híbrido para minimizar la desviación entre la calificación predicha y la calificación real otorgada por el usuario en el pasado. Un RMSE reducido indica que el sistema ha logrado una gran fidelidad en sus predicciones, convirtiéndolo en una herramienta robusta para la toma de decisiones en entornos de producción.

5. Generación de Recomendaciones Explicables: El sistema no solo entrega una lista de títulos, sino que genera una narrativa que justifica cada sugerencia: Se recomienda este título por su afinidad con su historial y por ser tendencia en su ciudad durante el fin de semana.

6. Implementación de Interfaz en Streamlit: se desarrolló una aplicación interactiva utilizando Streamlit. Esta interfaz traduce la lógica matemática en una experiencia visual accesible, permitiendo a los evaluadores seleccionar perfiles de usuario en tiempo real y visualizar tanto las recomendaciones como las métricas de desempeño.

3. Información dataset

El taller fue desarrollado utilizando la información obtenida de datasets públicos relacionados con negocios y preferencias de usuarios.

Dataset utilizado:

Plataforma: Kaggle

Tipo de información:

- Nombre del negocio

- Categoría
- Ubicación (Ciudad y estado)
- Ratings
- Reviews

Filtrado de Interacciones Mínimas y Calidad del Dataset

En esta etapa se aplica un criterio de densidad mínima para garantizar que el modelo aprenda de datos significativos y no de ruido estadístico.

Umbral de Actividad: Se filtran los datos utilizando los parámetros MIN_USER_REVIEWS y MIN_BUSINESS_REVIEWS (ambos fijados en 3). Esto asegura que solo se incluyan usuarios que han calificado al menos 3 negocios y negocios que han recibido al menos 3 reseñas.

Estado Final del Dataset:

- Volumen: El conjunto de datos final quedó conformado por 15,634 registros.
- Alcance: Se consolidó una base de 3,828 usuarios únicos y 3,921 negocios únicos.
- Sesgo de Calificación: Se observa un rating promedio de 3.84, lo que indica una tendencia positiva en las valoraciones del dataset procesado.

División de Datos (Train/Test Split)

En esta etapa se establece el protocolo de pruebas necesario para garantizar que el sistema sea capaz de realizar predicciones precisas sobre datos que no ha visto anteriormente.

Estrategia de Partición: El conjunto de datos se dividió utilizando un 20% para pruebas (test_df) y el 80% restante para entrenamiento (train_df).

Resultados de la División:

- Entrenamiento: 12,507 registros, utilizados para que el modelo aprenda los patrones de gusto y contexto.
- Prueba: 3,127 registros, reservados exclusivamente para la validación científica de los resultados.

4. Resumen Técnico: Sistema de Recomendación Híbrido (Yelp)

1. Arquitectura del Modelo

El sistema implementa un enfoque híbrido que combina dos componentes principales:

- Filtrado Colaborativo: Basado en factorización matricial mediante TruncatedSVD, entrenado estrictamente sobre la matriz usuario-negocio de los datos de entrenamiento.
- Modelo Contextual: Calcula un score dinámico fundamentado en la ciudad, la categoría principal y la condición de fin de semana.

2. Integración y Pesos (Alpha)

La fusión de ambos modelos se define mediante una ponderación balanceada:

- $\alpha = 0.10$: Peso asignado al componente SVD.
- $1 - \alpha = 0.90$: Peso asignado al componente contextual.

3. Protocolo de Evaluación

La validación del modelo se realizó mediante métricas estándar de la industria:

- Error de Predicción: RMSE y MAE.
- Ranking y Relevancia: Precision@10, Recall@10 y NDCG@10.

4. Explicabilidad y UX

El sistema fue desarrollado utilizando una arquitectura compuesta por:

- Backend en Python
- Interfaz web interactiva en Streamlit
- Modelos de recomendación híbridos

Motor de similitud basado en embeddings TF-IDF

El flujo general del sistema es:

1. El usuario selecciona preferencias o restaurantes de interés.
2. El sistema calcula similitudes entre restaurantes.
3. Se generan recomendaciones híbridas.
4. Se muestran explicaciones asociadas a cada recomendación.

5. Métricas del Modelo

- Configuración del Modelo y Validación ($N_FACTORS$, $TEST_SIZE$)
 $N_FACTORS$ define cuántos gustos ocultos (temas latentes) intentará descubrir el algoritmo SVD, para el taller se eligió el valor de 30 ya que es un equilibrio ideal para capturar la complejidad de los usuarios sin sobrecargar el sistema.
- $TEST_SIZE$ establece que reservaremos el 20% de nuestros datos exclusivamente para pruebas, permitiéndonos verificar si el modelo realmente aprendió a predecir o si solo memorizó los datos de entrenamiento.
- Estrategia de Recomendación y Pesos Híbridos (TOP_K , $ALPHA_HYBRID$)
- TOP_K determina que al usuario final se le presentarán las 10 mejores recomendaciones.
- Los parámetros MIN y MAX_ALPHA_HYBRID son las reglas del modelo: aseguran que el sistema siempre sea una mezcla real entre los gustos históricos del usuario y el contexto actual, impidiendo que una técnica tome totalmente el control.
- Estructura de Salida ($OUTPUT_DIR$)

Este parámetro define la carpeta de entrega donde el sistema guardará automáticamente todos los resultados, gráficos y modelos entrenados.

6. Entrenamiento de los modelos

Filtrado Colaborativo (SVD)

En este bloque se construye el núcleo de personalización del sistema mediante la técnica de factorización matricial. Se entrena TruncatedSVD únicamente con train_df. La matriz usuario-item se representa como matriz dispersa.

Preparación de la Matriz Dispersa: Se transforma el conjunto de entrenamiento en una matriz de tipo csr_matrix (Compressed Sparse Row), donde las filas representan a los usuarios y las columnas a los negocios. Esta estructura optimiza el uso de memoria al procesar únicamente las interacciones existentes (calificaciones de estrellas).

Mapeo e Indexación: Se crean diccionarios bidireccionales (user_to_idx, item_to_idx) para traducir las identidades reales de Yelp a índices numéricos procesables por el algoritmo.

Reducción de Dimensionalidad con TruncatedSVD:

Se configuraron 30 factores latentes (n_components), que representan las dimensiones ocultas (como estilo, precio o ambiente) que el modelo detecta automáticamente a partir de los datos.

- User Factors (3795, 30): La representación del perfil de gusto de cada usuario en el espacio latente.
- Item Factors (3593, 30): Las características aprendidas de cada negocio en ese mismo espacio.

El modelo alcanza una varianza explicada acumulada de 0.11. En sistemas de recomendación con matrices altamente dispersas (como Yelp), este valor es suficiente para capturar las tendencias generales de comportamiento sin caer en el ruido.

Predicción SVD

Se implementa una estrategia de dos capas para asegurar que siempre haya una respuesta para el usuario:

- Capa Predictiva (Producto Punto): Si el usuario y el negocio ya son conocidos por el sistema, se calcula la afinidad matemática multiplicando sus vectores latentes. Esto es lo que permite la personalización.
- Capa de Respaldo (Baseline): Si el usuario o el negocio son nuevos (problema de Cold Start), el sistema utiliza promedios históricos. Primero intenta promediar las

calificaciones del usuario y del negocio; si no tiene nada, usa el promedio global de la plataforma.

Restricción de Rango: Finalmente, usa `np.clip` para obligar a que cualquier resultado matemático esté entre 1 y 5 estrellas, evitando valores fuera de la realidad del negocio.

Modelo Sensible al Contexto

El modelo contextual a diferencia del SVD, que se basa en el comportamiento histórico del usuario, este componente analiza cómo factores externos influyen en la calidad percibida de un negocio.

Agregación de Estadísticas Contextuales: Se genera una tabla de referencia (`context_stats`) que calcula el promedio de estrellas (`context_score`) para cada combinación única de ciudad, categoría principal y estado del fin de semana. Esto permite identificar, por ejemplo, si los restaurantes en una ciudad específica tienden a ser mejor calificados los domingos que los lunes.

Volumen: Se generó una matriz de conocimiento contextual basada en las tendencias del set de entrenamiento.

- Estrategia de Predicción Multinivel (Fallback): Para garantizar que el modelo siempre devuelva un valor, la función `predict_context` utiliza una jerarquía de búsqueda:
- Match Exacto: Busca la puntuación promedio para la combinación específica de ciudad/categoría/fin de semana.
- Aproximación por Categoría: Si no hay datos suficientes de la ciudad, usa el promedio general de la categoría del negocio.
- Aproximación por Ciudad: Si la categoría es nueva, usa el promedio de la ciudad.
- Media Global: Como último recurso, utiliza el promedio general de todo el dataset.

Resultados en el Test Set: Se observa la creación de la columna `pred_context`, la cual proporciona una estimación de la calificación basada puramente en el entorno situacional del negocio, sirviendo como el contrapeso ideal para la personalización del SVD en la fase híbrida.

7. Evaluación de Regresión (RMSE y MAE)

En este apartado se realiza la validación numérica de los dos modelos base (SVD y Contextual) mediante métricas de error estándar.

Interpretación de Resultados:

- Modelo Contextual (RMSE: 1.1415, MAE: 0.8824): Presenta el mejor desempeño predictivo. Esto indica que en este dataset de Yelp, las variables de ubicación, categoría y temporalidad son predictores confiables de la calidad de un negocio.
- SVD - Factorización (RMSE: 2.8837, MAE: 2.6112): Muestra un error mayor. Esto se debe habitualmente a la alta dispersión de la matriz (sparsity); es decir, tenemos pocos datos históricos por cada usuario para que la factorización matricial logre una precisión exacta por sí sola.

8. Sintonización del peso Alpha

Tras realizar una búsqueda por rejilla (Grid Search) para balancear los componentes de Factorización Matricial (SVD) y Modelo Contextual, se obtuvieron las siguientes conclusiones:


- Dominancia del Contexto: El análisis del rango completo revela que los errores más bajos (RMSE) se encuentran cuando el peso del contexto es predominante (0.90 a 1.0). Esto demuestra que, para este conjunto de datos de Yelp, las variables externas (ciudad, categoría y día de la semana) tienen un poder predictivo superior a la afinidad histórica individual capturada por el SVD.
- Selección del Punto Óptimo: Se definió un Alpha de 0.1 para el SVD y 0.9 para el Contexto. Esta configuración fue seleccionada bajo una restricción de hibridación, buscando que el modelo no dependiera exclusivamente del promedio contextual, permitiendo así que el componente SVD aporte el factor de personalización necesario para diferenciar las recomendaciones entre usuarios en un mismo contexto.

Comparativa de Modelos:

Modelo Híbrido (RMSE: 1.1625): Logró un buen rendimiento, manteniéndose muy cerca del modelo contextual pero con la ventaja competitiva de ser un sistema personalizado.

SVD Individual (RMSE: 2.8837): Presentó el error más alto, confirmando que la factorización matricial por sí sola sufre ante la alta dispersión de datos, validando la necesidad de la arquitectura híbrida.

9. Grafica RMSE VS ALPHA



La gráfica representa la relación entre el peso asignado al modelo de personalización (Alpha SVD) y el error global del sistema (RMSE).

Comportamiento del Error: Se observa que a medida que aumentamos el valor de Alpha (dándole más peso al SVD y menos al Contexto), el RMSE sube de forma pronunciada. Esto indica que el modelo de factorización matricial por sí solo es menos preciso que el análisis del entorno para este conjunto de datos.

Selección del punto óptimo la línea punteada en Alpha = 0.1 marca el equilibrio elegido. En este punto, el error es mínimo (cerca de 1.16), permitiendo que el sistema sea estable, pero mantenga un 10% de influencia de los gustos específicos del usuario.

10. Resultados experimentales

Los resultados obtenidos demostraron que el model híbrido presentó un mejor desempeño comparado con los modelos individuales. En general tiene la mayor precisión, obtiene mejor recall y consigue el mejor NDCG, indicando un ranking más útil y relevante.

	modelo	precision@10	recall@10	ndcg@10
0	SVD - Factorización	0.101577	0.999781	0.742006
1	Modelo contextual	0.101577	0.999781	0.747643
2	Modelo híbrido SVD + Contexto	0.101623	0.999836	0.747665

Aunque las diferencias en Precisión@10 y Recall@10 son pequeñas, la mejora en NDCG@10 sugiere que incorporar la información contextual ayuda a ordenar mejor las recomendaciones, haciendo que los usuarios encuentren antes los ítems más relevantes.

11. Resultados de la aplicación

La aplicación desarrollada permite al usuario interactuar con el sistema de recomendación de forma intuitiva.

Las funcionalidades implementadas incluyen:

- Búsqueda de negocios
- Visualización de recomendaciones
- Explicación de recomendaciones
- Filtrado por categorías
- Visualización de información detallada

La interfaz fue desarrollada utilizando la librería Strealit, permitiendo una experiencia interactiva y sencilla para el usuario final.

Durante las pruebas realizadas, el sistema mostró recomendaciones coherentes y alineadas con las preferencias seleccionadas.

12. Aspectos logrados y no logrados

En el desarrollo del taller se logró la implementación de un sistema híbrido funcional, integración de técnicas NLP, generación de recomendaciones personalizadas, implementación de explicaciones y desarrollo de una aplicación interactiva.

Entre las iniciativas de potencial implementación se encuentra el feedback en tiempo real, cold start para usuarios nuevos en el sistema, aprendizaje online y retroalimentación dinámica del usuario.

13. Conclusiones

El desarrollo del sistema permitió aplicar técnicas de recomendación híbrida y procesamiento de lenguaje natural para un problema real de personalización.

En los resultados experimentales se demostró que el modelo híbrido supera a los enfoques individuales, logrando mejores métricas de precisión y relevancia. Con la incorporación de explicaciones en las recomendaciones se mejoró la interpretabilidad del sistema y también le da un plus a la experiencia de usuario.

Durante el desarrollo del taller se evidenció la importancia de combinar múltiples fuentes de información para generar recomendaciones más robustas y personalizadas.